TRABALHO PRÁTICO
ALINHAMENTO DE DUAS SEQUÊNCIAS

Especificação do trabalho

Ciência da Computação • Bioinformática • Programação Dinâmica

Escopo: exatamente duas sequências de DNA por execução

Sumário

1. Introdução 2
2. Entrada e Validação 2
   2.1 Sequências de entrada 2
   2.2 Tipo de alinhamento 3
   2.3 Parâmetros de pontuação 3
   2.4 Validações obrigatórias 3
3. Processamento 3
   3.1 Estrutura geral 3
   3.2 Função de pontuação 3
   3.3 Alinhamento Local — Smith-Waterman 4
   3.4 Alinhamento Global — Needleman-Wunsch 4
   3.5 Direções e traceback 4
   3.6 Empates 4
   3.7 Exemplo de alinhamento global 5
   3.8 Exibição da matriz 5
   3.9 Comparação Local × Global 5
   3.10 Complexidade 5
4. Saída 5
   4.1 Informações obrigatórias 5
   4.2 Representação do alinhamento 5
   4.3 Interface 6

4.4 Resultado esperado 6
Escopo final do trabalho 7
Apêndice – Modelos de Telas de Entrada, Processamento e Saída 8

1. Introdução

O alinhamento de sequências é uma das tarefas fundamentais da Bioinformática. Ele permite comparar sequências biológicas e identificar regiões de similaridade, substituições, inserções e deleções. Neste trabalho, deverá ser desenvolvido um programa capaz de alinhar exatamente duas sequências de DNA por execução, utilizando técnicas de programação dinâmica.

O programa deverá implementar dois métodos de alinhamento:

- Alinhamento Local, utilizando o algoritmo de Smith-Waterman;
- Alinhamento Global, utilizando o algoritmo de Needleman-Wunsch.

O objetivo principal é compreender e implementar a construção da matriz de programação dinâmica, o cálculo do score, o traceback e a reconstrução do alinhamento. O mesmo par de sequências deverá poder ser processado pelos dois métodos, permitindo observar as diferenças entre alinhamento local e global.

Os algoritmos deverão ser implementados pelos próprios alunos. Não será permitido utilizar bibliotecas ou serviços que realizem diretamente o alinhamento ou devolvam pronta a matriz de programação dinâmica.

2. Entrada e Validação

2.1 Sequências de entrada

Cada execução deverá receber exatamente duas sequências de DNA, identificadas como Seq1 e Seq2. As sequências poderão ser digitadas diretamente na interface ou carregadas de arquivo .txt ou .fasta.

```
>Seq1
ACGTAC

>Seq2
ACGTTC
```

Serão aceitas apenas as bases A, C, G e T. Letras minúsculas deverão ser convertidas automaticamente para maiúsculas.

2.2 Tipo de alinhamento

O usuário deverá escolher um dos modos: LOCAL ou GLOBAL. LOCAL executará Smith-Waterman; GLOBAL executará Needleman-Wunsch.

2.3 Parâmetros de pontuação

Os valores de Match, Mismatch e Gap deverão ser informados pelo usuário e não poderão ficar fixos no código-fonte. Exemplo:

```
Match:      +2
Mismatch:   -1
Gap:        -2
```

Para esta versão do trabalho será utilizada penalidade linear de gap. Não será exigido modelo de gap affine (abertura e extensão separadas).

2.4 Validações obrigatórias

- Quantidade diferente de duas sequências;
- Sequência vazia;
- Caractere diferente de A, C, G ou T;
- Parâmetro de pontuação ausente ou não numérico;
- Arquivo inexistente, ilegível ou em formato incompatível.

```
ACGTAXTG
     ↑
ERRO – base inválida: X
```

O processamento somente deverá iniciar após a validação das duas sequências e dos parâmetros.

3. Processamento

3.1 Estrutura geral

O processamento deverá seguir as etapas: validar a entrada; criar a matriz; inicializar a matriz conforme o método escolhido; preencher as células; identificar o ponto inicial do traceback; executar o traceback; reconstruir as duas sequências alinhadas; calcular e apresentar o score final.

3.2 Função de pontuação

Para cada comparação entre bases, deverá ser aplicada a função definida pelos parâmetros do usuário: bases iguais recebem Match; bases diferentes recebem Mismatch; base alinhada com gap recebe Gap.

Situação	Pontuação
A × A	Match
A × C	Mismatch
A × -	Gap
- × A	Gap

3.3 Alinhamento Local — Smith-Waterman

No alinhamento local, a primeira linha e a primeira coluna da matriz deverão ser inicializadas com zero. Cada célula H(i,j) deverá receber o maior valor entre zero, diagonal + score da comparação, célula superior + Gap e célula à esquerda + Gap.

```
H(i,j) = max(
    0,
    H(i-1,j-1) + score(Seq1[i], Seq2[j]),
    H(i-1,j)   + Gap,
    H(i,j-1)   + Gap
)
```

O traceback deverá começar na célula de maior valor de toda a matriz e terminar quando atingir uma célula de valor zero. O score do alinhamento local será o valor da célula em que o traceback começou.

3.4 Alinhamento Global — Needleman-Wunsch

No alinhamento global, a primeira linha e a primeira coluna deverão ser inicializadas com penalidades acumuladas de gap. Se Gap = -2, por exemplo, a inicialização será 0, -2, -4, -6, ...

```
F(i,j) = max(
    F(i-1,j-1) + score(Seq1[i], Seq2[j]),
    F(i-1,j)   + Gap,
    F(i,j-1)   + Gap
)
```

O traceback deverá começar na célula inferior direita e terminar na origem da matriz. O score do alinhamento global será o valor da célula inferior direita.

3.5 Direções e traceback

Durante o preenchimento, o programa deverá manter informação suficiente para reconstruir o caminho escolhido. Cada movimento representa uma operação:

Movimento	Interpretação
Diagonal	Base de Seq1 alinhada com base de Seq2
Vertical	Base de Seq1 alinhada com gap em Seq2
Horizontal	Gap em Seq1 alinhado com base de Seq2

Um gap não deverá ser inserido simplesmente porque um valor ficou negativo. O gap é consequência da escolha do caminho de maior score acumulado entre as alternativas permitidas pelo algoritmo.

3.6 Empates

Uma mesma célula poderá possuir duas ou três alternativas com o mesmo valor máximo. Para que as implementações sejam determinísticas, deverá ser adotada a seguinte prioridade em caso de empate: diagonal, vertical e, por último, horizontal. Dessa forma, para a mesma entrada e os mesmos parâmetros, todos os grupos deverão produzir o mesmo alinhamento.

3.7 Exemplo de alinhamento global

Considere as sequências Seq1 = ACGTAC e Seq2 = ACGTTC, com Match = +2, Mismatch = -1 e Gap = -2. Como as sequências possuem o mesmo comprimento e diferem apenas na quinta posição, um alinhamento global possível é:

```
Seq1: A C G T A C
      | | | | . |
Seq2: A C G T T C
```

Nesse caso, existem cinco matches e um mismatch. Portanto:

```
Score = 5 × (+2) + 1 × (-1) = 9
```

3.8 Exibição da matriz

A matriz de programação dinâmica deverá ser disponibilizada ao usuário. A interface poderá exibir apenas os valores numéricos ou, adicionalmente, as direções utilizadas no traceback. A visualização da matriz é requisito obrigatório, pois permite verificar o funcionamento da programação dinâmica.

3.9 Comparação Local × Global

O programa deverá permitir executar o mesmo par de sequências nos dois modos sem necessidade de alterar a entrada. O alinhamento global considera as sequências em toda a sua extensão, enquanto o alinhamento local procura a região de maior similaridade. Assim, os alinhamentos e scores obtidos podem ser diferentes.

3.10 Complexidade

Considerando sequências de comprimentos m e n, o preenchimento da matriz possui complexidade de tempo O(m × n). A implementação tradicional também utiliza O(m × n) de memória, pois a matriz completa deverá ser preservada para exibição e traceback. Os alunos deverão ser capazes de explicar essa complexidade.

4. Saída

4.1 Informações obrigatórias

Ao final do processamento, o programa deverá apresentar:

- Método utilizado: LOCAL ou GLOBAL;
- Sequências originais;
- Parâmetros Match, Mismatch e Gap;
- Matriz de programação dinâmica;
- Duas sequências alinhadas, incluindo os gaps inseridos;
- Indicação visual de matches, mismatches e gaps;
- Score final do alinhamento.

4.2 Representação do alinhamento

Uma possível representação textual é:

```
ALINHAMENTO GLOBAL

Match: +2   Mismatch: -1   Gap: -2

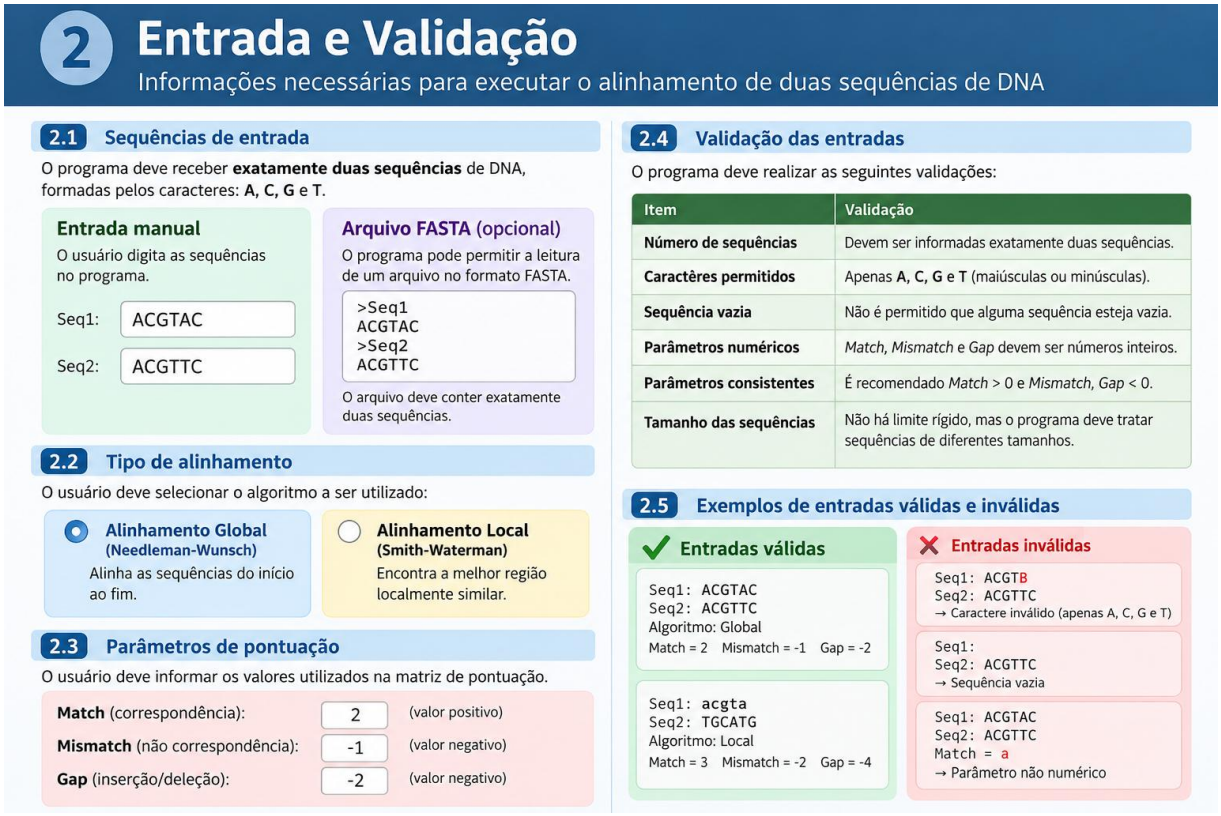
Seq1: A C G T A C
      | | | | . |
Seq2: A C G T T C

Score: 9
```

Sugere-se utilizar | para match, . para mismatch e espaço em posições envolvendo gap. Outra representação equivalente poderá ser adotada desde que seja explicada na interface.

4.3 Interface

A aplicação poderá ser desenvolvida em modo texto, desktop ou web. A escolha da linguagem de programação e da tecnologia de interface é livre, desde que os requisitos funcionais sejam atendidos.



4.4 Resultado esperado

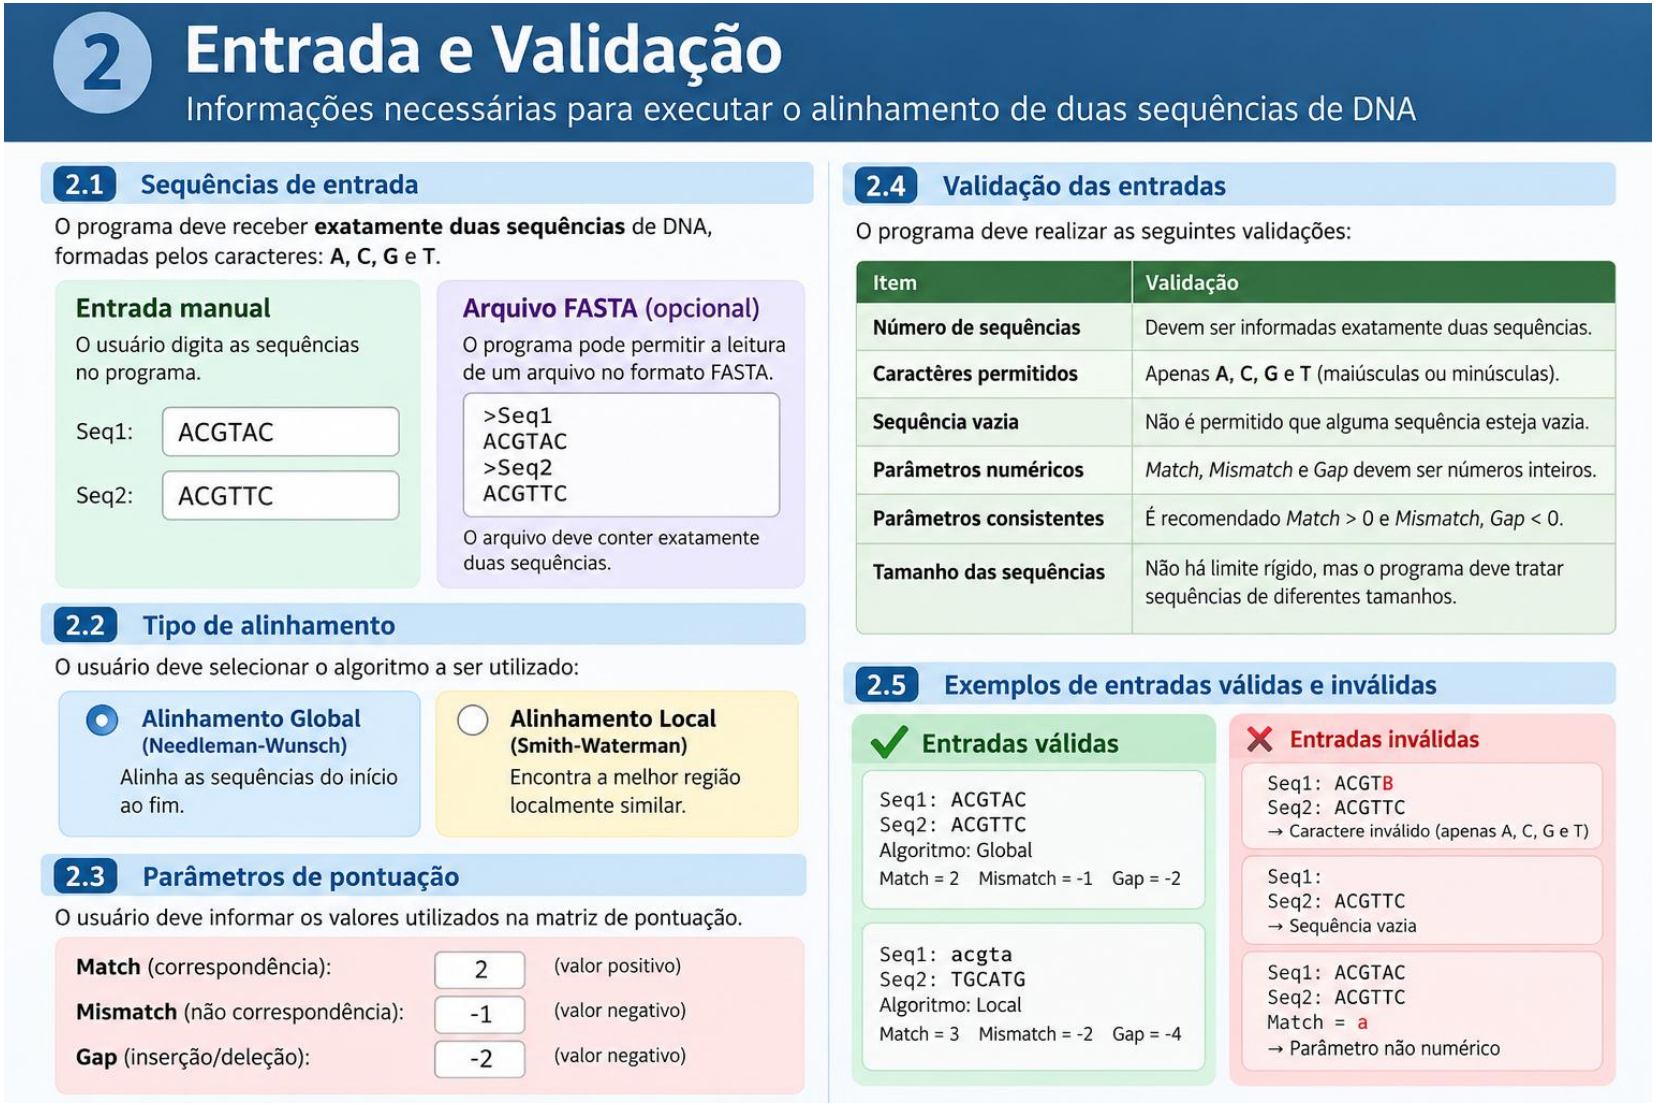
A saída deverá permitir que o usuário compreenda não apenas qual alinhamento foi obtido, mas também como a programação dinâmica chegou ao resultado. Por esse motivo, a matriz e o traceback são partes essenciais da solução e não deverão ser omitidos.

Escopo final do trabalho

O trabalho está restrito ao alinhamento de exatamente duas sequências por execução. Não fazem parte desta especificação alinhamento múltiplo, perfis, alinhamento Perfil × Sequência, Sum-of-Pairs, árvores-guia ou seleção progressiva de sequências.

O foco da avaliação será a implementação correta de Smith-Waterman e Needleman-Wunsch, a construção e visualização da matriz de programação dinâmica, o traceback, o cálculo do score, as validações de entrada e a clareza da interface e da saída.

Apêndice – Modelos de Telas de Entrada, Processamento e Saída



4 Saída – Exemplo de Resultados na Tela

Visualização dos principais resultados do alinhamento entre duas sequências de DNA

Entrada

Seq1:
ACGTAC

Seq2:
ACGTTC

Algoritmo:
- (●) **Global** (Needleman-Wunsch)
- ( ) **Local** (Smith-Waterman)

Parâmetros de pontuação

Match:	2
Mismatch:	-1
Gap:	-2

▶ Executar Alinhamento

Resultado Geral | Matriz de Pontuação | Matriz de Traceback | Alinhamento | Resumo

Algoritmo	Score final	Tamanho do alinhamento	Sequência 1	Sequência 2
Global (Needleman-Wunsch)	9	6	6	6

Matriz de Pontuação

	-	A	C	G	T	T	C
-	0	-2	-4	-6	-8	-10	-12
A	-2	**2**	0	-2	-4	-6	-8
C	-4	0	**4**	2	0	-2	-4
G	-6	-2	2	**6**	4	2	0
T	-8	-4	0	4	**8**	6	4
A	-10	-6	-2	2	6	**7**	5
C	-12	-8	-4	0	4	5	**9**

Matriz de Pontuação
Mostra o valor calculado em cada célula da programação dinâmica. O caminho do traceback aparece destacado em vermelho.

Matriz de Traceback

	-	A	C	G	T	T	C
-	·	←	←	←	←	←	←
A	↑	↖	←	←	←	←	←
C	↑	↑	↖	←	←	↑	↖
G	↑	↑	↑	↖	←	←	↑
T	↑	↑	↑	↑	↖	←	←
A	↑	↑	↑	↑	↑	↖	←
C	↑	↑	↑	↑	↑	↑	↖

Matriz de Traceback
Cada célula contém a direção de onde veio o melhor score:
- ↖ diagonal
- ↑ acima
- ← esquerda
- · início (apenas no alinhamento local)

Alinhamento Final

```
Seq1:  A  C  G  T  A  C
       |  |  |  |  .  |
Seq2:  A  C  G  T  T  C

Score: 9
```

Alinhamento Final
Mostra as duas sequências alinhadas, com uma linha indicando coincidências (|), mismatches (.) e gaps (espaço ou -).

Resumo

Algoritmo:	Global (Needleman-Wunsch)
Match:	2
Mismatch:	-1
Gap:	-2
Score final:	9
Tamanho do alinhamento:	6

5 Exportando a Saída

Como salvar os resultados do alinhamento em arquivos

1 Executar o alinhamento

Após informar as sequências, o algoritmo e os parâmetros, clique em Executar.

Entrada

Seq1: ACGTAC

Seq2: ACGTTC

Algoritmo: (•) **Global** (Needleman-Wunsch) ( ) **Local** (Smith-Waterman)

Parâmetros:

Match: 2 Mismatch: -1 Gap: -2

▶ Executar Alinhamento

2 Visualizar os resultados

Os resultados serão exibidos na tela (matizes, alinhamento e resumo).

Resultado Geral | Matriz de Pontuação | Matriz de Traceback | Alinhamento | Resumo

Alinhamento Final

```
Seq1:  A C G T A C
       | | | | . |
Seq2:  A C G T T C
Score: 9
```

Resumo

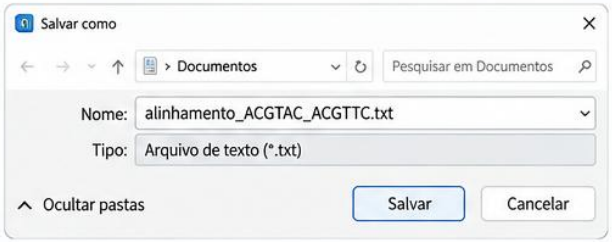
Algoritmo:	Global (Needleman-Wunsch)
Match:	2
Mismatch:	-1
Gap:	-2
Score final:	9
Tamanho do alinhamento:	6

3 Exportar os arquivos

Clique no botão **Exportar**. Os arquivos serão salvos na pasta escolhida.

Exportar

- Exportar como arquivo de texto (.txt)
- Exportar matrizes em CSV (.csv)
- Exportar todos os arquivos



4 Arquivos gerados

O programa deverá gerar, no mínimo, os seguintes arquivos:

✓ Os arquivos devem conter exatamente as informações mostradas na tela.

A Arquivo de texto (.txt)

Resumo completo dos resultados.

alinhamento_ACGTAC_ACGTTC.txt

```
Algoritmo: Global (Needleman-Wunsch)
Sequência 1: ACGTAC
Sequência 2: ACGTTC
Match:     2
Mismatch:  -1
Gap: -2
Score final: 9
Tamanho do alinhamento: 6

Alinhamento final:
Seq1:  A C G T A C
       | | | | . |
Seq2:  A C G T T C

Matriz de pontuação:
(ver arquivo CSV correspondente)

Matriz de traceback:
(ver arquivo CSV correspondente)
```

B Matriz de pontuação (.csv)

Contém todos os valores da matriz.

matriz_pontuacao_ACGTAC_ACGTTC.csv

	-	A	C	G	T	T	C
-	0	-2	-4	-6	-8	-10	-12
A	-2	2	0	-2	-4	-6	-8
C	-4	0	4	2	0	-2	-4
G	-6	-2	2	6	4	2	0
T	-8	-4	0	4	8	6	4
A	-10	-6	-2	2	6	7	5
C	-12	-8	-4	0	4	5	9

C Matriz de traceback (.csv)

Contém a direção de cada célula.

matriz_traceback_ACGTAC_ACGTTC.csv

	-	A	C	G	T	T	C
-	-	←	←	←	←	←	←
A	↑	↖	←	←	←	←	←
C	↑	↑	↖	←	←	↑	←
G	↑	↑	↑	↖	←	←	↑
T	↑	↑	↑	↑	↖	←	←
A	↑	↑	↑	↑	↑	↖	←
C	↑	↑	↑	↑	↑	↑	↖

D Alinhamento (.csv)

Contém o alinhamento final.

alinhamento_ACGTAC_ACGTTC.csv

Posição	Seq1	Linha	Seq2
1	A	|	A
2	C	|	C
3	G	|	G
4	T	|	T
5	A	.	T
6	C	|	C